

Informe Técnico Final ? Módulo 3

Asistente Corporativo Riopaila Castilla (Ruta A)

Equipo: TAMML ? Tarea 1

Empresa: Riopaila Castilla S.A. (Valle del Cauca)

Ruta elegida: A ? LangChain, FastAPI, WhatsApp V? a 2 (webhook propio en FastAPI)

1. Problema y solución

Problema

Stakeholders, accionistas y público general necesitan respuestas rápidas y verificables sobre Riopaila Castilla (NIT, contacto, sostenibilidad, gobierno corporativo, líneas de negocio) sin depender de navegar múltiples PDFs y secciones del sitio web.

Solución

Un agente conversacional productizado que:

- Consulta datos estructurados (company_info en Supabase) con esquemas Pydantic.
- Realiza RAG semántico sobre informes y comunicados indexados en pgvector.
- Mantiene memoria por sesión (número de teléfono o session_id) con PostgresSaver.
- Se expone vía API REST para canales externos (WhatsApp).

2. Evolución arquitectónica (Módulo 2 ? Módulo 3)

3. Arquitectura Ruta A (diagrama)

4. Componentes LangChain exigidos

5. API REST (productización)

- Framework: FastAPI (src/riopaila_rag/api/main.py)

- Endpoints:

- GET /health ? estado, tipo de checkpointer, WhatsApp configurado
- POST /chat ? { "message", "session_id" } ? { "reply", "session_id" }
- DELETE /chat/{session_id} ? limpiar hilo
- GET/POST /webhooks/whatsapp ? V? a 2 Meta (opcional)

El session_id se mapea a thread_id en LangGraph ? misma conversación para el mismo teléfono.

6. Integración WhatsApp (implementación activa: V? a 2)

V? a 2 ? Webhook en FastAPI (elegida en producción del proyecto)

- Módulo: src/riopaila_rag/api/whatsapp.py

- Flujo: Meta ? ngrok ? GET/POST /webhooks/whatsapp ? agente ? Graph API envía respuesta.

- Variables: WHATSAPP_VERIFY_TOKEN, WHATSAPP_ACCESS_TOKEN, WHATSAPP_PHONE_NUMBER_ID

- Formateo de respuesta: Markdown adaptado a WhatsApp (viñetas, negritas, secciones Fuentes).

- session_id = número del usuario (from) para memoria por teléfono.

Prueba en vivo: App Meta WA_MakilaGO, número sandbox +1 (555) 059-8036, testers registrados en API Setup.

V? a 1 ? N8N (documentada como alternativa)

Workflow y guías disponibles en docs/n8n/workflow_whatsapp_riopaila.json y docs/MODULO3_N8N_WHATSAPP.md.

Justificación V? a 2 vs N8N: Menor latencia (un solo salto), menos dependencias operativas el día de la sustentación, y control total del formateo y manejo de errores en Python.

7. Gestión de errores

- Tools devuelven [HERRAMIENTA_NO_DISPONIBLE] con alternativas (tool_errors.py).
- API responde 503 si falta configuración; 500 genérico sin filtrar secretos.
- WhatsApp: mensaje amigable si el agente lanza excepción.

8. Bonus t-SNE (ruta transversal A)

1. Cada turno v?a API/WhatsApp se guarda en conversation_logs (84+ registros tras seed).
2. Script scripts/run_tsne.py (o notebook notebooks/tsne_conversaciones.ipynb) genera embeddings OpenAI y proyecta con t-SNE.
3. Gr?fico exportado: docs/tsne_conversaciones.png.

Interpretaci?n (ejecuci?n real ? 84 conversaciones)

Conclusiones operativas:

- El asistente concentra tr?fico en consultas legales/identificaci?n, coherente con el caso de uso Riopaila.
- El volumen en otros sugiere ampliar etiquetado o prompts para sostenibilidad/gobierno (menos datos de esas categor?as en los logs actuales).
- Los puntos aislados en t-SNE corresponden a mensajes at?picos o sesiones de prueba durante desarrollo.

Comandos: python scripts/seed_conversation_logs.py --api http://127.0.0.1:8000 y python scripts/run_tsne.py

9. Repositorio y buenas pr?cticas

- C?digo en src/riopaila_rag/ con separaci?n agent / tools / api / config.
- Migraciones versionadas en supabase/migrations/.
- .env.example sin secretos; verificaci?n con scripts/verify_modulo3.py.
- Streamlit permanece como panel de demostraci?n interna, no como producto final.

10. Conclusiones

El M?dulo 3 convierte el prototipo Streamlit en un servicio desplegable alineado con la r?brica: Function Calling estricto, API REST, canal WhatsApp y trazabilidad para an?lisis. La sustentaci?n en vivo debe mostrar el flujo tel?fono ? API ? agente ? respuesta con memoria de contexto.

Referencias r?pidas

- MODULO3.md ? resumen de etapas
- docs/CHECKLIST_ENTREGA_MODULO3.md ? pasos operativos
- docs/SUSTENTACION_EN_VIVO.md ? guion de 15 minutos